

# 概率统计 总复习

# 各章要点

## 第一章

- 1. 概率性质 古典概率
- 2. 条件概率 { 乘法公式  
全、贝公式
- 3. 事件独立性

## 第二章

- 1. 分布律分布函数定义性质
- 2. 七个常用分布
- 3. 随机变量的函数的分布

## 第三章

1. 联合分布律 分布函数定义性质
2. 边缘分布 条件分布
3. 随机变量的独立性
4. 随机变量的函数的分布

## 第四章

1. 期望 方差定义 性质
2. 相关系数 相关性
3. 期望的应用
4. 大数定律 中心极限定理  
切贝雪夫不等式

# 第一章

- 古典概率及概率的基本性质
- 条件概率
- 乘法公式 全概率公式 贝叶斯公式
- 事件的独立性

# 概率的定义

$\Omega$  是随机试验  $E$  的样本空间，如果对每个随机事件  $A$  定义一个实数  $P(A)$ ，满足：

(1) (非负性) 对任意事件  $A$ ，有  $P(A) \geq 0$ ；

(2) (规范性) 对必然事件  $\Omega$ ，有  $P(\Omega) = 1$ ；

(3) (无穷可加性) 对任意两两不相容的随机事件  $A_1, A_2, \dots$ ，都有：

$$P(A_1 + A_2 + \dots) = P(A_1) + P(A_2) + \dots$$

这个函数  $P(A)$  就称为随机事件  $A$  的**概率**。

# 概率的基本性质

(1)  $P(\phi) = 0$  ;

(2) 若 $A_1, \dots, A_n$ 两两互斥, 则有:

$$P(A_1 + \dots + A_n) = P(A_1) + \dots + P(A_n);$$

(3)  $P(\bar{A}) = 1 - P(A)$

(4)  $P(A \cup B) = P(A) + P(B) - P(AB)$  (加法公式)

## 推论

(5) 若 $A \subset B$ , 则有 $P(A) \leq P(B)$

(6)  $P(A) \leq 1$

## 三个随机事件的加法公式

$$\begin{aligned} P(A \cup B \cup C) = & P(A) + P(B) + P(C) \\ & - P(AB) - P(BC) - P(AC) + P(ABC) \end{aligned}$$

## n个随机事件的加法公式

$$\begin{aligned} P\left(\bigcup_{i=1}^n A_i\right) = & \sum_{i=1}^n P(A_i) - \sum_{1 \leq i < j \leq n} P(A_i A_j) + \sum_{1 \leq i < j < k \leq n} P(A_i A_j A_k) \\ & + \cdots + (-1)^{n-1} P(A_1 A_2 \cdots A_n) \end{aligned}$$



## 古典概率的计算公式

$$P(A) = \frac{\text{随机事件 } A \text{ 包含的样本点个数}}{\text{样本空间 } \Omega \text{ 包含的样本点总数}}$$

## 几何概率的计算公式

$$P(A) = \frac{m(A)}{m(\Omega)}$$

其中 $m(\cdot)$  表示集合的度量(长度、面积或体积)

若某批产品中有a件次品，b件好品. 在以下条件下分别抽取n件产品，求恰有k件次品( $k \leq a$ )的概率.

(1)不放回抽取; (2)有放回抽取.

(1) 不放回抽取, 取到k件次品的概率是  $P_1 = \frac{C_a^k C_b^{n-k}}{C_{a+b}^n}$

此式也叫作超几何分布的概率公式

(2) 有放回抽取, 取到k件次品的概率是

$$P_2 = \frac{C_n^k a^k b^{n-k}}{(a+b)^n} = C_n^k \left( \frac{a}{a+b} \right)^k \left( 1 - \frac{a}{a+b} \right)^{n-k}$$

此式也叫作二项分布的概率公式

# 条件概率的定义

$A$ 、 $B$  是两个随机事件，如果  $P(A) > 0$ ，则定义：

$$P(B | A) = \frac{P(AB)}{P(A)}$$

是随机事件  $A$  发生的条件下随机事件  $B$  发生的条件概率。

## 条件概率的性质

(1) 非负性:  $P(B|A) \geq 0$ ;

(2) 规范性:  $P(\Omega|A) = 1$ ;

(3) 可列可加性: 对于无穷个两两互斥的事件  $B_1, B_2, \dots$

$$P(B_1 \cup B_2 \cup \dots | A) = P(B_1 | A) + P(B_2 | A) + \dots$$

# 乘法公式

如果  $P(A) > 0$ , 则  $P(AB) = P(A)P(B|A)$

如果  $P(B) > 0$ , 则  $P(AB) = P(B)P(A|B)$

## 一般的乘法公式

$A_1, A_2, \dots, A_n$  是任意  $n$  个随机事件,  
并且  $P(A_1 A_2 \dots A_n) > 0$ , 则有:

$$\begin{aligned} P(A_1 A_2 \dots A_n) = & \\ & P(A_1) \times P(A_2 | A_1) \times P(A_3 | A_1 A_2) \times \dots \times \\ & P(A_{n-1} | A_1 A_2 \dots A_{n-2}) \times P(A_n | A_1 A_2 \dots A_{n-1}) \end{aligned}$$

设试验E的样本空间为 $\Omega$ , A为E的事件,  $P(A)>0$ .

$B_1, B_2, \dots, B_n$  是 $\Omega$ 的一个划分, 且 $P(B_i)>0, i=1,2,\dots,n$ .

## 全概率公式

$$P(A) = \sum_{i=1}^n P(B_i) \cdot P(A | B_i)$$

## 贝叶斯(Bayes)公式

$$P(B_i | A) = \frac{P(B_i) \cdot P(A | B_i)}{\sum_{i=1}^n P(B_i) \cdot P(A | B_i)}$$

**$A$ 、 $B$  是两个随机事件，如果满足：**

$$P(AB) = P(A) P(B)$$

**则称随机事件  $A$  与  $B$  相互独立。**

**事件独立的另一种理解：**

$$P(B/A) = P(B)$$

**若事件 $A$ 、 $B$ 相互独立，则**

**$A$ 与 $\bar{B}$ ， $\bar{A}$ 与 $B$ ， $\bar{A}$ 与 $\bar{B}$ ，**

**也相互独立。**

- 如果三个事件**A, B, C**满足

$$P(AB)=P(A)P(B);$$

$$P(AC)=P(A)P(C);$$

$$P(BC)=P(B)P(C),$$

则称**A, B, C**两两独立.

又若满足

$$P(ABC)=P(A)P(B)P(C),$$

则称**A, B, C**相互独立.

- 一般地，设 $A_1, A_2, \dots, A_n$ 为 $n$ 个事件，如果对任意的 $1 < k \leq n$ ，以及任意的

$$1 \leq i_1 \leq i_2 \leq \dots \leq i_k \leq n,$$

都有

$$P(A_{i_1} A_{i_2} \dots A_{i_k}) = P(A_{i_1}) P(A_{i_2}) \dots P(A_{i_k}),$$

则称 $A_1, A_2, \dots, A_n$ 相互独立.



当 $P(A\text{发生}) = p$ ,  $P(A\text{不发生}) = q = 1 - p$ ,  
每次试验的结果要么  $A$  发生, 要么  $A$  不发生。  
独立重复进行  $n$  次试验, 其中  $A$  恰好发生  $k$  次  
的概率是:

$$p_k = C_n^k p^k q^{n-k}, \quad 0 \leq k \leq n$$

**此概率称为二项概率.**

# 第二章

- 离散型随机变量及分布律
- 连续型随机变量及密度函数
- 分布函数
- 随机变量函数的分布

# 随机变量的基本分类

1. **离散型随机变量**：所有可能的取值是有限、或可数无穷多个；

例如古典概率问题所涉及的随机变量。

2. **非离散型随机变量**：所有可能的取值是不可数无穷多个。

**连续型随机变量**：即在某个连续区间或整个实数轴上取值。

例如几何概率问题所涉及的随机变量。

# 常见的离散型随机变量

## 1. 0-1变量及其分布 (也称两点分布或Bernoulli 分布)

分布律为:  $P\{X=1\}=p, P\{X=0\}=q=1-p$

## 2. 二项变量及其分布

$X$  全部可能取值是有限整数  $0, 1, \dots, n$  ;

分布律为:

$$p_k = C_n^k p^k q^{n-k}, \quad 0 \leq k \leq n$$

这里参数  $0 < p < 1, q = 1 - p$  .

称为参数为 $n, p$ 的二项分布,记作:  $X \sim B(n, p)$

两点分布就是  $n = 1$  时的二项分布

### 3. Poisson (泊松) 变量及其分布

可能取值是所有非负整数  $0, 1, 2, \dots$  ; 分布律为:

$$P\{X = k\} = \frac{\lambda^k}{k!} e^{-\lambda}, \quad k \geq 0$$

这里泊松分布的参数  $\lambda > 0$ 。

记为:  $X \sim P(\lambda)$

### 4. 超几何变量及其分布

有N件产品, 其中M件次品, 从中抽取n件, 则抽取出的次品数X的分布率为

$$P\{X = k\} = \frac{C_M^k C_{N-M}^{n-k}}{C_N^n}, \quad k = l_1, l_1 + 1, \dots, l_2.$$

其中  $l_1 = \max\{0, n - (N - M)\}$ ,  $l_2 = \min\{n, M\}$ .

## 5. 几何变量及其分布

独立重复进行Bernoulli试验, 直到事件A(这里假设  $P(A)=p$ )首次发生为止所进行的试验次数X的分布率为:

$$P\{X=k\}=(1-p)^{k-1}p, k=1,2,\dots$$

称为参数为p的**几何分布**, 记 $X\sim G(p)$ .

X称为**几何变量**.

**几何分布具有无记忆性**

$$\begin{aligned} &P\{\text{m次后的第k次A发生} \mid \text{前m次A未发生}\} \\ &= \frac{(1-p)^{m+k-1}p}{(1-p)^m} = (1-p)^{k-1}p \end{aligned}$$

# 引申

## (1) 关于二项分布的一个性质:


$P\{X=x\}$  在  $x=[(n+1)p]$  处达到最大值.

其中  $[y]$  表示不超过  $y$  的最大整数.

使  $P\{X=x\}$  达到最大值的二项变量的取值  $x^*$  称为 **最可能数**.

注: 当  $(n+1)p$  为整数时,  $P\{X=x\}$  在  $x=(n+1)p-1$  与  $x=(n+1)p$  两处同时达到最大值.

## (2) 几个分布之间的关系:



# 常见连续型随机变量

## 1. 均匀变量及其分布, $X \sim U(a, b)$

概率密度函数:

$$f(x) = \begin{cases} \frac{1}{b-a}, & a < x < b \\ 0, & \text{其它} \end{cases}$$

## 2. 指数变量及其分布, $X \sim E(\lambda)$

概率密度函数:

$$f(x) = \begin{cases} \lambda e^{-\lambda x}, & x > 0 \\ 0, & \text{其它} \end{cases}$$



# 指数分布的无记忆性

$$\begin{aligned}P\{X > m+t / X > m\} &= \frac{P\{X > m+t, X > m\}}{P\{X > m\}} \\&= \frac{P\{X > m+t\}}{P\{X > m\}} = \frac{e^{-\lambda(m+t)}}{e^{-\lambda m}} = e^{-\lambda t} = P\{X > t\}\end{aligned}$$

**服从指数分布的元件对已使用过的m小时没有记忆。**

### 3. 正态变量及其分布, $X \sim N(\mu, \sigma^2)$

概率密度函数:

$$f(x) = \frac{1}{\sqrt{2\pi}\sigma} e^{-\frac{(x-\mu)^2}{2\sigma^2}}, \quad -\infty < x < +\infty$$

标准正态变量,  $X \sim N(0,1)$

**参数  $\mu=0$ ,  $\sigma=1$  的正态分布**

**标准正态变量的密度函数**

$$\varphi(x) = \frac{1}{\sqrt{2\pi}} e^{-\frac{x^2}{2}}, \quad -\infty < x < +\infty$$

$$\Phi(x) = \int_{-\infty}^x \frac{1}{\sqrt{2\pi}} e^{-\frac{t^2}{2}} dt$$

**$\Phi(x)$ 的函数值可查表得到。有关性质：**

**(1)  $\Phi(0)=0.5$**

**(2)  $\Phi(-x)=1-\Phi(x)$**

**(3)  $\Phi(x)$ 是 $x$ 的单调增函数**

**(4)  $\Phi(-\infty)=0, \quad \Phi(+\infty)=1$**

## **正态分布的 “ $3\sigma$ ” 原则**

**对任意参数的正态分布  $N(\mu, \sigma^2)$ , 正态变量 $X$ 的取值几乎都落在区间 $(\mu-3\sigma, \mu+3\sigma)$  内.**

设  $X \sim N(0, 1)$ , 对任意给定的  $\alpha (0 < \alpha < 1)$ , 称使

$$P\{X > z_\alpha\} = \alpha$$

成立的  $z_\alpha$  为标准正态分布  $N(0, 1)$  的 **上 $\alpha$ 分位数**.

易见  $\Phi(z_\alpha) = 1 - \alpha$ , 故可查表求得  $z_\alpha$

# 分布函数

对任意实数  $x$ ，根据概率生成的函数


$$F(x) = P \{ X \leq x \}$$

称为是  $X$  的分布函数。

## 主要性质

1. **非负有界**  $0 \leq F(x) \leq 1$  ;
2. **单调性** 当  $x_1 < x_2$ , 则  $F(x_1) \leq F(x_2)$  ;
3. **极限性质**  $F(-\infty) = \lim_{x \rightarrow -\infty} F(x) = 0$  ,  
 $F(+\infty) = \lim_{x \rightarrow +\infty} F(x) = 1$  ;
4. **右连续性**  $F(a) = F(a+0)$

# 离散随机变量分布函数的图形



离散随机变量分布函数与分布率的关系

$$P\{X=x\}=F(x)-F(x-0)$$

# 连续型随机变量分布函数与密度函数的关系

**密度函数是分布函数的一阶导数，  
分布函数是密度函数的一个特殊原函数。**

$$F(x) = \int_{-\infty}^x f(t) dt \Leftrightarrow f(x) = \partial F(x) / \partial x$$

# 连续型随机变量的函数分布的求法

若已知变量 $X$ 的密度函数 $f_X(x)$ ,  $Y=g(X)$ , 则

第一步: 求 $Y$ 的分布函数  $F_Y(y)$ ;

$$F_Y(y) = P\{Y \leq y\} = P\{g(X) \leq y\} = \int_{g(x) \leq y} f_X(x) dx$$

第二步: 由 $F_Y(y)$ 关于 $y$ 求导, 得到变量 $Y$ 的密度函数 $f_Y(y)$

$$f_Y(y) = \frac{dF_Y(y)}{dy}$$



# 第三章

- 二维离散型随机变量及分布律
- 二维连续型随机变量及密度函数
- 分布函数
- 随机变量的独立性
- 随机变量函数的分布

## 二维离散型随机变量的边缘分布律

(1)  $X$  的边缘分布律  $\{p_{i\cdot}, i \geq 1\}$

$$p_{i\cdot} = P\{X = x_i\} = \sum_{j \geq 1} p_{ij}$$

(2)  $Y$  的边缘分布律  $\{p_{\cdot j}, j \geq 1\}$

$$p_{\cdot j} = P\{Y = y_j\} = \sum_{i \geq 1} p_{ij}$$

只需把联合分布律表格中的每一行、每一列分别相加就得到边缘分布律。

## 二维离散型随机变量的条件分布律

如果 $p_{\cdot j} > 0$ , 则定义

$$P\{X=x_i|Y=y_j\} = \frac{P\{X=x_i, Y=y_j\}}{P\{Y=y_j\}} = \frac{p_{ij}}{p_{\cdot j}}$$

为在 $Y=y_j$ 条件下 $X$ 的条件分布律

同理, 如果 $p_{i \cdot} > 0$ , 则定义

$$P\{Y=y_j|X=x_i\} = \frac{P\{X=x_i, Y=y_j\}}{P\{X=x_i\}} = \frac{p_{ij}}{p_{i \cdot}}$$

为在 $X=x_i$ 条件下 $Y$ 的条件分布律

# 二维连续随机向量的边缘密度

(1)  $X$  的边缘密度函数  $f_X(x)$

$$f_X(x) = \int_{-\infty}^{+\infty} f(x, y) dy$$

(2)  $Y$  的边缘密度函数  $f_Y(y)$

$$f_Y(y) = \int_{-\infty}^{+\infty} f(x, y) dx$$

## 二维连续随机向量的条件密度函数

如果对某个固定实数  $x$  有  $f_X(x) > 0$ , 则定义

$$f_{Y|X}(y|x) = \frac{f(x,y)}{f_X(x)}, \quad (\text{对于所有实数 } y)$$

是  $Y$  关于随机事件  $(X = x)$  的条件密度函数

# 独立性的判断

## 1. 离散随机变量的独立

联合分布律等于边缘分布律的乘积：

$$p_{ij} = p_{i\cdot} \times p_{\cdot j} \text{ 对全部 } i、j \text{ 成立}$$

## 2. 连续随机变量的独立

联合密度函数等于边缘密度函数的乘积：

$$f(x,y) = f_X(x) \times f_Y(y) \text{ 对全部 } x、y \text{ 成立}$$

## 特例 对于二维正态分布

$$(X, Y) \sim N(\mu_1, \mu_2; \sigma_1^2, \sigma_2^2; \rho)$$

$X$ 、 $Y$ 相互独立的充分必要条件是  $\rho = 0$ 。

## 连续随机变量和 $Z=X+Y$ 的密度公式

$$f_Z(z) = \int_{-\infty}^{+\infty} f(x, z-x) dx$$

$$f_Z(z) = \int_{-\infty}^{+\infty} f(z-y, y) dy$$

# 第四章

- 期望
- 方差
- 协方差，相关系数
- 矩
- 中心极限定理与大数定律



## 1. 离散型随机变量的数学期望

如果 $X$  的分布律  $P\{X=x_i\}=p_i, i=1,2,\dots$ , 满足

$$\sum_i |x_i p_i| < \infty$$

则  $X$  的**数学期望**定义为:  $E(X) = \sum_i x_i p_i$

## 2. 连续型随机变量的数学期望

如果 $X$  的密度函数  $f(x)$  满足

$$\int_{-\infty}^{+\infty} |xf(x)| dx < +\infty$$

则连续随机变量  $X$  的**数学期望**是积分:

$$E(X) = \int_{-\infty}^{+\infty} xf(x) dx$$

## 随机变量的函数的期望 (一维离散型)

如果 $X$  的分布律  $P\{X=x_i\}=p_i, i=1,2,\dots,$

$Y=g(X)$ ,  $g$ 为连续函数, 若  $\sum_i |g(x_i)p_i| < \infty$

则有

$$E(Y) = \sum_i g(x_i)p_i$$

## 随机变量的函数的期望 (一维连续型)

如果 $X$  的密度函数为  $f(x)$ ,  $Y=g(X)$ ,  $g$ 为连续函数, 若

$$\int_{-\infty}^{+\infty} |g(x)f(x)| dx < \infty$$

则有

$$E(Y) = \int_{-\infty}^{+\infty} g(x)f(x)dx$$

# 方差的定义

如果  $(X - E(X))^2$  的数学期望存在,  
即  $E(X - E(X))^2 < +\infty$  ,  
则称

$D(X) = E(X - E(X))^2$   
为X的**方差**, 有时也记为 $\text{Var}(X)$ 。

常用计算公式:  $D(X) = E(X^2) - (E(X))^2$

# 常用变量的数学期望与方差

1. $X$ 服从0-1分布, $E(X)=p$	$D(X)=p(1-p)$
--------------------------	---------------

2. $X \sim B(n,p)$ , $E(X)=np$	$D(X)=np(1-p)$
--------------------------------	----------------

3. $X \sim P(\lambda)$ , $E(X)=\lambda$	$D(X)=\lambda$
---	----------------

4. $X \sim U(a,b)$ , $E(X)=(a+b)/2$	$D(X)=(b-a)^2/12$
-------------------------------------	-------------------

5. $X \sim E(\lambda)$ , $E(X)=1/\lambda$	$D(X)=1/\lambda^2$
---	--------------------

6. $X \sim N(\mu, \sigma^2)$ , $E(X)=\mu$	$D(X)=\sigma^2$
---	-----------------

## $X$ 、 $Y$ 之间的协方差定义

$$Cov(X, Y) = E[(X - EX)(Y - EY)]$$

## 协方差的计算公式

$$Cov(X, Y) = E(XY) - (EX)(EY)$$

设 $(X, Y)$ 是二维随机变量，当 $D(X) > 0$ ,  $D(Y) > 0$ 时，称

$$\rho(X, Y) = \frac{Cov(X, Y)}{\sqrt{D(X)}\sqrt{D(Y)}}$$

为 $X$ 与 $Y$ 的相关系数.

# 协方差矩阵

设 $(X_1, X_2, \dots, X_n)$ 是 $n$ 维随机变量,  $\text{Cov}(X_i, X_j) = c_{ij}$ ,  $i, j = 1, 2, \dots, n$ , 则矩阵

$$\begin{pmatrix} c_{11} & c_{12} & \cdots & c_{1n} \\ c_{21} & c_{22} & \cdots & c_{2n} \\ \vdots & \vdots & \ddots & \vdots \\ c_{n1} & c_{n2} & \cdots & c_{nn} \end{pmatrix}$$

称为 $(X_1, X_2, \dots, X_n)$ 的协方差矩阵.

**协方差矩阵为对称矩阵**

**对于n元正态变量( $X_1, X_2, \dots, X_n$ ),**

**若令**

$$\mathbf{x} = \begin{pmatrix} x_1 \\ x_2 \\ \vdots \\ x_n \end{pmatrix} \quad \boldsymbol{\mu} = \begin{pmatrix} \mu_1 \\ \mu_2 \\ \vdots \\ \mu_n \end{pmatrix} \quad \mathbf{C} = \begin{pmatrix} c_{11} & c_{12} & \cdots & c_{1n} \\ c_{21} & c_{22} & \cdots & c_{2n} \\ \vdots & \vdots & \ddots & \vdots \\ c_{n1} & c_{n2} & \cdots & c_{nn} \end{pmatrix}$$

**其中C为协方差矩阵**

**则n元正态变量( $X_1, X_2, \dots, X_n$ )的概率密度函数可写为**

$$f(x_1, x_2, \dots, x_n) = \frac{1}{(2\pi)^{n/2} (|\mathbf{C}|)^{1/2}} e^{-\frac{1}{2}(\mathbf{x}-\boldsymbol{\mu})^T \mathbf{C}^{-1}(\mathbf{x}-\boldsymbol{\mu})}$$

# 相关系数的性质

(1)  $\rho(X, Y) = \rho(Y, X)$ ;

(2)  $|\rho(X, Y)| \leq 1$ ;

(3)  $|\rho(X, Y)| = 1$ 的充分必要条件是:

存在常数 $a, b$ , 使  $P\{Y = aX + b\} = 1$ , 且

当 $a > 0$ 时  $\rho(X, Y) = 1$ ;

当 $a < 0$ 时  $\rho(X, Y) = -1$ .



# 相关系数的意义

相关系数 $\rho(X,Y)$ 用来度量随机变量 $X, Y$ 之间的线性关系紧密程度

$$|\rho(X,Y)|=1,$$

**$X$ 与 $Y$ (以概率1) 成立线性关系**

$$\rho(X,Y)=1,$$

**$X$ 与 $Y$  正线性相关**

$$\rho(X,Y)=-1,$$

**$X$ 与 $Y$  负线性相关**

$$\rho(X,Y)=0,$$

**$X$ 与 $Y$ 不(线性)相关**

$$0<\rho(X,Y)<1,$$

$$|\rho(X,Y)|\text{接近}1$$

**$X$ 与 $Y$ 的线性关系比较紧密**

$$|\rho(X,Y)|\text{接近}0$$

**$X$ 与 $Y$ 的线性关系比较弱**

**$E(X^k)$ : 称为 $X$ 的 $k$ 阶原点矩**

**$E[(X-E(X))^k]$ : 称为 $X$ 的 $k$ 阶中心矩**

**$E(X^k Y^l)$ : 称为 $(X, Y)$ 的 $(k, l)$ 阶混合原点矩**

**$E[(X-E(X))^k (Y-E(Y))^l]$ : 称为 $(X, Y)$ 的 $(k, l)$ 阶混合中心矩**

# 契比雪夫(Chebyshev)不等式

假设  $EX = \mu$  ,  $DX = \sigma^2$  , 则对于任意正实数  $\varepsilon$  , 有:

$$P\{|X - \mu| \geq \varepsilon\} \leq \frac{\sigma^2}{\varepsilon^2};$$

# 契比雪夫(Chybeshev)大数定理

设随机变量 $X_1, X_2, \dots, X_n$ , 相互独立, 且具有相同的数学期望( $E(X_i)=\mu, i=1,2,\dots,n$ )和方差( $D(X_i)=\sigma, i=1,2,\dots,n$ ), 若令

$$\bar{X} = \frac{1}{n} \sum_{i=1}^n X_i$$

则对任意 $\varepsilon > 0$ , 有

$$\lim_{n \rightarrow \infty} P\left\{|\bar{X} - \mu| < \varepsilon\right\} = 1$$

## 契比雪夫大数定理的推论: **伯努利大数定理**

设 $n_A$ 是 $n$ 次独立重复试验中事件 $A$ 发生的次数,  $p$ 是事件 $A$ 在每次试验中发生的概率, 则对任意正数 $\varepsilon$ , 有

$$\lim_{n \rightarrow \infty} P \left\{ \left| \frac{n_A}{n} - p \right| < \varepsilon \right\} = 1$$

## 契比雪夫大数定理的推论: **辛钦大数定理**

设随机变量 $X_1, X_2, \dots, X_n$ , 相互独立, 服从同一分布, 且具有相同的数学期望( $E(X_i) = \mu, i=1, 2, \dots, n$ ), 则对任意 $\varepsilon > 0$ , 有

$$\lim_{n \rightarrow \infty} P \left\{ \left| \frac{1}{n} \sum_{i=1}^n X_i - \mu \right| < \varepsilon \right\} = 1$$

# 列维-林德伯格(Levy-Lindberg)定理 (独立同分布的中心极限定理)

设随机变量 $X_1, X_2, \dots, X_n$  相互独立, 服从同一分布, 具有相同的数学期望和方差:  $E(X_i)=\mu$ ,  $D(X_i)=\sigma^2>0$ ,  $i=1,2,\dots,n$ , 则对于任意 $x$ , 总有

$$\lim_{n \rightarrow \infty} P \left\{ \frac{\sum_{i=1}^n X_i - n\mu}{\sqrt{n}\sigma} \leq x \right\} = \Phi(x) = \frac{1}{\sqrt{2\pi}} \int_{-\infty}^x e^{-\frac{t^2}{2}} dt$$

## 中心极限定理的推论

# 棣莫佛-拉普拉斯(De Moivre-Laplace)定理

设随机变量 $\eta_n \sim B(n, p)$ ,  $i=1, 2, \dots, n$ . 则对任意 $x$ , 有

$$\lim_{n \rightarrow \infty} P\left\{\frac{\eta_n - np}{\sqrt{np(1-p)}} \leq x\right\} = \Phi(x) = \frac{1}{\sqrt{2\pi}} \int_{-\infty}^x e^{-\frac{t^2}{2}} dt$$